



MCDIA500 • PROGRAMACIÓN PARA LA CIENCIA DE DATOS

MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

UNIVERSIDAD ANDRÉS BELLO

Análisis de ofertas en licitaciones públicas del sector Salud

Sumativa 1: Avance del proyecto Fases 1 y 2 – Entorno reproducible, exploración y procesamiento inicial de datos

Reporte oficial de marzo de 2026

Grupo 5

Víctor Bravo Barrera

Nayadeth Garrido Ibáñez

Alexander Sepulveda

Docente: Omar Salinas Silva

Fecha: 16 de septiembre de 2026

Índice de contenidos

I. Introducción y contextualización	3
Conexión explícita con las fases F1–F4 del proyecto	3
II. Definición de la problemática y objetivos del proyecto.....	4
Preguntas específicas del estudio	4
Objetivos del proyecto	4
Alcance, restricciones y supuestos analíticos	4
III. Herramientas científicas, reproducibilidad y control de versiones	5
Arquitectura modular y estructura del repositorio	5
Gestión colaborativa y control de versiones.....	5
IV. Diseño de soluciones algorítmicas, preprocesamiento y validación (F2)	7
A. Codificación funcional modular	7
B. Preprocesamiento, transformaciones y tratamiento de NA.....	7
C. Validación técnica y verificación del código.....	8
V. Resultados preliminares de la preparación de datos (F1 y F2)	9
Tasa de adjudicación según tamaño de proveedor	9
Distribución por tipo de licitación y plazos administrativos	9
VI. Vinculación del mapa conceptual con el avance del proyecto	10
VII. Referencias bibliográficas (Normas APA 7.ª edición)	12
VIII. Anexos técnicos y trazabilidad criptográfica	13

El presente documento consolida íntegramente los avances exigidos para las Fases 1 y 2 del proyecto transversal, integrando la definición de la problemática, la arquitectura reproducible, la exploración rigurosa, el pipeline de transformación de datos y la validación técnica.

I. Introducción y contextualización

Las compras públicas en Chile constituyen uno de los mecanismos más relevantes de asignación de recursos fiscales, donde el sector Salud representa un volumen crítico de contrataciones de insumos, equipamiento y servicios clínicos esenciales (ChileCompra, s. f.-a). A través de la plataforma Mercado Público, gestionada por la Dirección de Compras y Contratación Pública (ChileCompra), los organismos de salud publican sus requerimientos y reciben propuestas de múltiples proveedores bajo diversas modalidades de licitación.

El presente estudio analiza el reporte de contrataciones del sector Salud correspondiente a marzo de 2026, el cual reúne 44.226 registros y 74 columnas. Una característica estructural fundamental de este conjunto de datos, señalada por ChileCompra (s. f.-a), es que cada fila representa una oferta individual asociada a un ítem específico dentro de un proceso de licitación. En consecuencia, el número de observaciones no equivale a la cantidad de licitaciones únicas: un mismo proceso licitatorio (`NroLicitacion``) puede albergar múltiples productos o líneas de cotización y recibir propuestas concurrentes de diversos oferentes.

El problema central que aborda esta investigación consiste en determinar cómo varía la proporción de ofertas ganadoras según el tipo de licitación y el tamaño del proveedor en las adquisiciones de salud. Dado el volumen de transacciones y la presencia de variables categóricas, monetarias y temporales heterogéneas, la resolución de este problema demanda un tratamiento programático riguroso sustentado en el ecosistema científico de Python (NumPy, Pandas) y prácticas estrictas de reproducibilidad computacional (Samuel & Mietchen, 2024).

Conexión explícita con las fases F1–F4 del proyecto

El proyecto se articula en una progresión metodológica de cuatro fases interdependientes:

Fase 1 (Implementada): Delimitación de la problemática, preguntas de análisis, objetivos, supuestos teóricos, diseño de la arquitectura modular y configuración del entorno reproducible verificado.

Fase 2 (Implementada): Diagnóstico exploratorio de calidad de datos, desarrollo del pipeline modular de limpieza (exclusión de columnas nulas y neutralización de fechas anómalas año 1900), transformaciones de tipos, validación técnica automatizada y exportación del dataset preprocesado a `data/processed/`.

Fase 3 (Proyectada): Análisis exploratorio bivariado y multivariado, modelación estadística de tasas de adjudicación y visualización analítica avanzada con librerías científicas de Python.

Fase 4 (Proyectada): Consolidación de hallazgos, evaluación del impacto de las políticas de compra pública en el sector salud, discusión de limitaciones y formulación de recomendaciones finales.

II. Definición de la problemática y objetivos del proyecto

La adquisición pública de bienes y servicios médicos exige maximizar la transparencia y la libre concurrencia de proveedores. No obstante, surge la interrogante de si la probabilidad de adjudicación de una oferta difiere sistemáticamente en función de la capacidad económica de la empresa oferente (TamanoProveedor: Micro, Pequeña, Mediana, Grande o NoClasificado) y de la envergadura del mecanismo contractual (TipoLicitacion: pública o privada, según rangos en UTM).

Pregunta central de investigación: ¿Cómo varía la proporción de ofertas registradas como ganadoras según el tipo de licitación y el tamaño del proveedor en el reporte del sector Salud de marzo de 2026?

Preguntas específicas del estudio

¿Cuál es la distribución de ofertas e ítems licitados entre las diferentes categorías de tamaño de proveedor y tipos de licitación pública?

¿Qué porcentaje de ofertas resulta efectivamente adjudicado dentro de cada estrato empresarial y cómo influye el estado administrativo del proceso (adjudicada vs. desierta, revocada o cerrada)?

¿Qué inconsistencias estructurales, columnas vacías o codificaciones anómalas (fechas en 1900, categorías no clasificadas) condicionan la validez de las métricas de éxito en los datos de compras públicas?

Objetivos del proyecto

Objetivo General: Analizar descriptivamente las diferencias en la proporción de ofertas ganadoras según el tipo de licitación y el tamaño del proveedor en el sector Salud durante marzo de 2026, mediante un flujo de ingeniería de datos y programación científica completamente reproducible y validado.

Objetivos Específicos:

1. Delimitar conceptualmente la unidad de análisis, variables clave, restricciones y configurar un entorno reproducible trazable bajo control de versiones (F1).
2. Caracterizar la estructura de las 74 variables, diseñar e implementar un pipeline modular de limpieza y transformación de datos, y verificar su robustez técnica mediante pruebas de casos límite y excepciones (F2).
3. Construir distribuciones, cruces de contingencia y visualizaciones efectivas que revelen la brecha de éxito entre micro, pequeñas, medianas y grandes empresas (F3).
4. Integrar los resultados técnicos, evidencias de ejecución y análisis crítico en un reporte formal orientado a la toma de decisiones en políticas públicas de abastecimiento sanitario (F4).

Alcance, restricciones y supuestos analíticos

El análisis se define bajo los siguientes supuestos y límites metodológicos:

Enfoque descriptivo: Las asociaciones encontradas describen comportamientos del periodo observado y no implican causalidad ni juicio sobre la eficiencia contractual.

Cobertura temporal y geográfica: El archivo comprende ofertas del reporte de marzo de 2026 del sector Salud chileno, con publicaciones ocurridas entre el 15 de enero y el 25 de marzo de 2026 y cierres concentrados en marzo de 2026.

Granularidad de fila: Cada observación representa una oferta para una línea de producto; por ende, varias filas pueden corresponder a una misma licitación y proveedor.

Métrica de adjudicación: La proporción de éxito se calcula como el total de ofertas ganadoras dividido por el total de ofertas con resultado válido en procesos formalmente concluidos, informando explícitamente los denominadores.

III. Herramientas científicas, reproducibilidad y control de versiones

Para asegurar que cualquier investigador pueda replicar íntegramente los resultados en un entorno computacional independiente (Samuel & Mietchen, 2024; Universidad Andrés Bello, 2026), se configuró un entorno virtual aislado (.venv) bajo Python 3.12.14 en arquitectura x64.

Herramienta / Librería	Versión verificada	Función en el proyecto
Python	3.12.14	Intérprete base de ejecución estructurada y scripting modular.
pandas	3.0.1	Manipulación tabular, preprocesamiento, casting datetime y cálculo de frecuencias.
NumPy	2.3.5	Operaciones vectorizadas, manejo de valores nulos (np.nan) y aserciones numéricas.
JupyterLab / ipykernel	4.6.3 / 7.3.0	Entorno interactivo reproducible que integra narrativa técnica, código y salidas.
Git / GitHub	2.x	Sistema distribuido de control de versiones y trazabilidad colaborativa.
nbclient / nbformat	0.11.0 / 5.11.1	Automatización de ejecución desatendida y verificación técnica de notebooks.

Arquitectura modular y estructura del repositorio

El proyecto adopta el principio de separación de responsabilidades (McKinney, 2022). La lógica computacional reusable reside en el módulo `src/proyecto.py`, mientras que los cuadernos interactivos `F1/F1_Definición.ipynb` y `F2/F2_Preprocesamiento.ipynb` invocan estas funciones y presentan la narrativa analítica:

`src/proyecto.py`: Contiene funciones puras para registro de versiones, cálculo de huellas SHA-256, lectura con contrato de esquema, diagnóstico EDA, pipeline de limpieza y suite de validación.

`data/raw/`: Almacena el dataset original `licitaciones_salud_marzo_2026.csv` (68,96 MB) con hash inmutable SHA-256.

`data/processed/`: Aloja el producto derivado limpio `licitaciones_salud_marzo_2026_procesado.csv` listo para análisis analítico.

`evidencias/`: Conserva los registros estructurados JSON (`F1_ejecucion.json` y `F2_ejecucion.json`) emitidos tras ejecuciones exitosas.

`docs/`: Reúne el informe integrado en Word/PDF y el modelo conceptual técnico editable en draw.io.

Gestión colaborativa y control de versiones

El desarrollo se gestionó en GitHub en el repositorio público <https://github.com/vbravo29/sumativo-1> sobre la rama activa desarrollo, manteniendo un historial transparente con aportes individuales verificables de cada integrante del Grupo 5:

Commit	Autor registrado	Hito técnico alcanzado
56a6536	Alexander Sepulveda	Incorporación de metadatos y validación de cobertura institucional.
9b53d5e	Alexander Sepulveda	Configuración de notebook validador de umbrales del curso en <code>data/raw</code> .

Commit	Autor registrado	Hito técnico alcanzado
7565825	Nayadeth Garrido Ibáñez	Estructuración institucional del documento y diseño de apartados formales.
72fd51c	Nayadeth Garrido Ibáñez	Corrección de referencias de lectura y contrato de parámetros en validador.
25f4703	Víctor Bravo Barrera	Carga del dataset de salud (44.226 filas) y registro de hash SHA-256.
34d92c2	Víctor Bravo Barrera	Implementación de lectura modular y pruebas unitarias de F1.
596a0d0	Víctor Bravo Barrera	Diccionario de 74 variables y formalización del mapa conceptual técnico.
fa710bc	Grupo 5	Implementación del pipeline F2, pruebas de casos límite y reporte integrado.

IV. Diseño de soluciones algorítmicas, preprocesamiento y validación (F2)

Esta sección detalla el desarrollo técnico de la Fase 2, evidenciando la construcción de scripts funcionales, el tratamiento justificado de valores faltantes y la ejecución de pruebas sistemáticas sobre los datos.

A. Codificación funcional modular

La ingeniería de datos se implementó a través de funciones estructuradas en `src/proyecto.py` con parámetros explícitos, manejo de excepciones y validación de precondiciones:

`resumen_exploracion(df)`: Computa el inventario de filas, columnas, variables sin nulos, columnas con nulos parciales, columnas 100% vacías y campos constantes.

`limpiar_datos_f2(df, excluir_vacias=True, normalizar_texto=True)`: Ejecuta las transformaciones de limpieza sobre una copia profunda del DataFrame, asegurando la inmutabilidad de la entrada.

`validar_dataset_procesado(df)`: Ejecuta un conjunto de 6 aserciones lógicas que comprueban la ausencia de columnas vacías, completitud de variables clave, ausencia de fechas de 1900 e integridad de filas.

`exportar_datos_procesados(df, ruta_salida)`: Serializa el dataset limpio a CSV e informa su peso en MB y su huella criptográfica SHA-256.

B. Preprocesamiento, transformaciones y tratamiento de NA

El análisis exploratorio de las 74 variables iniciales reveló anomalías estructurales que fueron intervenidas con criterios explícitos y reproducibles:

Variable o Componente	Problema detectado	Tratamiento aplicado en F2	Justificación metodológica
LicitacionBaseTipo, ContratoRenovable, UnidadTiempoRenovacion	100% de valores nulos (44.226 filas vacías).	Exclusión directa del conjunto de datos.	No aportan variabilidad ni información a ninguna etapa del análisis.
FechaEstimadaEvaluacionOfertas	7.613 filas registran fechas del año 1900 (1900-01-11, etc.).	Conversión sistemática a NaT.	Son fechas anómalas por defecto del sistema origen (año 1900); utilizarlas distorsionaría el cómputo de plazos.
FechaPublicacion, FechaCierre, FechaAdjudicacion	Almacenadas como cadenas de texto (str).	Casting a <code>datetime64[ns]</code> mediante <code>pd.to_datetime</code> .	Habilita operaciones temporales y cómputo de plazos administrativos.
TamanoProveedor	3.410 ofertas registran la etiqueta NoClasificado.	Preservación explícita como categoría separada.	Imputar arbitrariamente distorsionaría la representación real de empresas en compras públicas.
ResultadoOferta vs. EstadoLicitacion	Ofertas en licitaciones desiertas o revocadas figuran como perdedoras.	Creación de flags <code>licitacion_adjudicada</code> y <code>oferta_ganadora</code> .	Permite aislar procesos adjudicados y calcular tasas de éxito reales sin sesgos.
plazo_cierre_dias	Variable no existente en el CSV original.	Cálculo de $(FechaCierre - FechaPublicacion)$ en días.	Métrica cuantitativa clave para caracterizar la urgencia o envergadura de las compras.

C. Validación técnica y verificación del código

Para garantizar que el pipeline funcione correctamente bajo diversos escenarios, se diseñó una batería automatizada de pruebas ejecutada en el notebook F2_Preprocesamiento.ipynb:

Caso de prueba	Escenario evaluado	Comportamiento esperado	Resultado
Caso Normal	Dataset real de 44.226 filas preprocesado.	Superar 6 aserciones de consistencia e integridad.	OK (6/6 superadas)
Caso Límite (Edge Case)	Registros con fechas año 1900 y categoría NoClasificado.	Fecha convertida a NaT y categoría preservada.	OK (Neutralización exitosa)
Caso Excepción 1	DataFrame sin la columna obligatoria ResultadoOferta.	Captura controlada de excepción KeyError.	OK (KeyError capturado)
Caso Excepción 2	DataFrame vacío (0 registros).	Captura controlada de excepción ValueError.	OK (ValueError capturado)

V. Resultados preliminares de la preparación de datos (F1 y F2)

Tras ejecutar el pipeline sobre el conjunto completo de licitaciones del sector Salud, se obtuvieron hallazgos cuantitativos sustantivos que validan la calidad del conjunto de datos preparado y dan respuesta sólida a las preguntas exploratorias planteadas para esta entrega.

Tasa de adjudicación según tamaño de proveedor

Al restringir el análisis a licitaciones adjudicadas (44.025 ofertas), se observa una correlación directa entre el tamaño del oferente y su probabilidad de éxito comercial:

Tamaño del Proveedor	Ofertas Ganadoras	Ofertas Perdedoras	Total Ofertas	% Ganadoras
Grande	12.575	6.255	18.830	66,78 %
Mediana	4.982	4.001	8.983	55,46 %
NoClasificado	1.803	1.576	3.379	53,36 %
Pequeña	5.022	4.577	9.599	52,32 %
Micro	1.680	1.554	3.234	51,95 %
Total Adjudicadas	26.062	17.963	44.025	59,20 %


Las empresas de tamaño Grande logran una tasa de éxito de 66,78 %, superando en casi 15 puntos porcentuales a las Microempresas (51,95 %) y Pequeñas empresas (52,32 %). Este resultado cuantitativo fundamenta la pertinencia de las hipótesis formuladas en la Fase 1.

Distribución por tipo de licitación y plazos administrativos

El tipo de licitación más frecuente corresponde a Licitación Pública Entre 100 y 1000 UTM (LE) con 23.708 ofertas, seguida de Licitación Pública Mayor 1000 UTM (LP) con 14.448 ofertas. El plazo promedio concedido a los proveedores entre la publicación de las bases y el cierre de recepción de propuestas fue de 14,38 días (desviación estándar de 6,86 días), con un mínimo de 4,92 días y un máximo de 61,03 días, ajustándose a los umbrales de la Ley N.º 19.886 de compras públicas.

VI. Vinculación del mapa conceptual con el avance del proyecto

El mapa conceptual técnico elaborado en docs/mapa_conceptual_f1_f2.drawio representa la arquitectura sistémica del proyecto. Refleja cómo la planificación conceptual se tradujo en artefactos técnicos concretos para F1 y F2, proyectando el trabajo restante hacia F3 y F4:



Flujo reproducible cerrado: datos originales inmutables -> código modular en src/ -> salidas y evidencias

Figura 1. Síntesis gráfica del mapa conceptual técnico del proyecto transversal. El archivo editable completo se encuentra disponible en docs/mapa_conceptual_f1_f2.drawio.

Componente del Mapa Conceptual	Estado en el Proyecto	Artefacto / Archivo de Respaldo en Repositorio
Problema, unidad de análisis y objetivos	Implementado (F1)	F1/F1_Definición.ipynb (secciones 1–4) y data/README.md
Entorno reproducible y dependencias	Implementado (F1)	requirements.txt, README.md y .venv verificado en Python 3.12
Código modular y contrato de entrada	Implementado (F1/F2)	src/proyecto.py (versiones_entorno, sha256, leer_datos_f1, limpiar_f2)
Exploración, diagnóstico y diccionario	Implementado (F2)	data/DICCIONARIO_VARIABLES.md y F2/F2_Preprocesamiento.ipynb
Limpieza de NA, fechas anómalas y transformaciones	Implementado (F2)	src/proyecto.py (limpiar_datos_f2) y F2_Preprocesamiento.ipynb
Dataset procesado derivado y trazable	Implementado (F2)	data/processed/licitaciones_salud_marzo_2026_procesado.csv
Evidencias de ejecución sin errores	Implementado (F1/F2)	evidencias/F1_ejecucion.json y evidencias/F2_ejecucion.json
Análisis estadístico bivariado y visualización	Proyectado (F3)	Planificado para desarrollo en semana 2 según pauta de Fase 3

Componente del Mapa Conceptual	Estado en el Proyecto	Artefacto / Archivo de Respaldo en Repositorio
Modelación integrada y conclusiones finales	Proyectado (F4)	Planificado para desarrollo en semana 3 según pauta de Fase 4

VII. Referencias bibliográficas (Normas APA 7.ª edición)

En estricto cumplimiento de los criterios institucionales de diversidad, actualidad y tipología de fuentes, se incorporan las referencias técnicas, académicas y docentes que respaldan este informe y los notebooks ejecutados:

ChileCompra. (s. f.-a). Descargas de datos abiertos del sistema de compras públicas. Dirección de Compras y Contratación Pública. <https://datos-abiertos.chilecompra.cl/descargas>

ChileCompra. (s. f.-b). Diccionario de datos de la API de Mercado Público: Licitaciones públicas. Dirección de Compras y Contratación Pública. <https://www.chilecompra.cl/wp-content/uploads/2026/03/Documentacion-API-Mercado-Publico-Licitaciones.pdf>

ChileCompra. (s. f.-c). Glosario y definiciones del portal de datos abiertos. Dirección de Compras y Contratación Pública. <https://datos-abiertos.chilecompra.cl/datos-abiertos/definiciones>

McKinney, W. (2022). Python for data analysis: Data wrangling with pandas, NumPy, and Jupyter (3.ª ed.). O'Reilly Media.

NumPy Developers. (s. f.). NumPy user guide and reference documentation (Versión 2.3). <https://numpy.org/doc/stable/>

Samuel, S., & Mietchen, D. (2024). Computational reproducibility of Jupyter notebooks from biomedical publications. *GigaScience*, 13, giad113. <https://doi.org/10.1093/gigascience/giad113>

The pandas development team. (s. f.). pandas documentation (Versión 3.0). <https://pandas.pydata.org/docs/>

Universidad Andrés Bello. (2026). Guía metodológica: Buenas prácticas de programación científica, control de versiones y reproducibilidad en Python (Material docente del curso MCDIA500: Programación para la Ciencia de Datos). Magíster en Ciencia de Datos e Inteligencia Artificial.

Universidad Andrés Bello. (2026). Pauta técnica y rúbrica de evaluación sumativa 1: Implementación inicial del entorno reproducible y preprocesamiento de datos (Documento de cátedra MCDIA500). Magíster en Ciencia de Datos e Inteligencia Artificial.

VIII. Anexos técnicos y trazabilidad criptográfica

A continuación se resumen las características de los artefactos clave del repositorio que respaldan la reproducibilidad y verosimilitud de la entrega:

Artefacto / Archivo	Ruta en Repositorio	Tamaño	Huella criptográfica SHA-256 / Identificador
Dataset crudo original	data/raw/licitaciones_salud_marzo_2026.csv	68,96 MB	490d9209a10d387011d481b72b7891f26e997974ec2cf9dfc518aa4a08552232
Dataset preprocesado F2	data/processed/licitaciones_salud_marzo_2026_procesado.csv	68,16 MB	7e835d6725d8c4f9aa64ad97a294dc38fcc341e71373f544c7f6b8ba2ff31dc5
Notebook Fase 1	F1/F1_Definición.ipynb	26 KB	143a94be1a21bfb47b0a2760a2b9496cd4dc979e3be638d2a2d8fbf7bc0be80b
Notebook Fase 2	F2/F2_Preprocesamiento.ipynb	28 KB	5ef3bb377ddba7cdf3b5c4bba6d76214c355be8a6fdb22d2433e3210879108e4
Módulo de ingeniería	src/proyecto.py	5,8 KB	Funciones de entorno, hash, lectura, limpieza y validación
Evidencia Fase 1	evidencias/F1_ejecucion.json	447 B	4 celdas ejecutadas, 0 errores, kernel Python 3.12
Evidencia Fase 2	evidencias/F2_ejecucion.json	508 B	9 celdas ejecutadas, 0 errores, kernel Python 3.12